

Шипицын Кирилл Васильевич



Возможности

- Проверка текста на соответствие шаблону
- Поиск текста по шаблону
- Извлечение текста по шаблону
- Замена текста по шаблону



Виды регулярных выражений

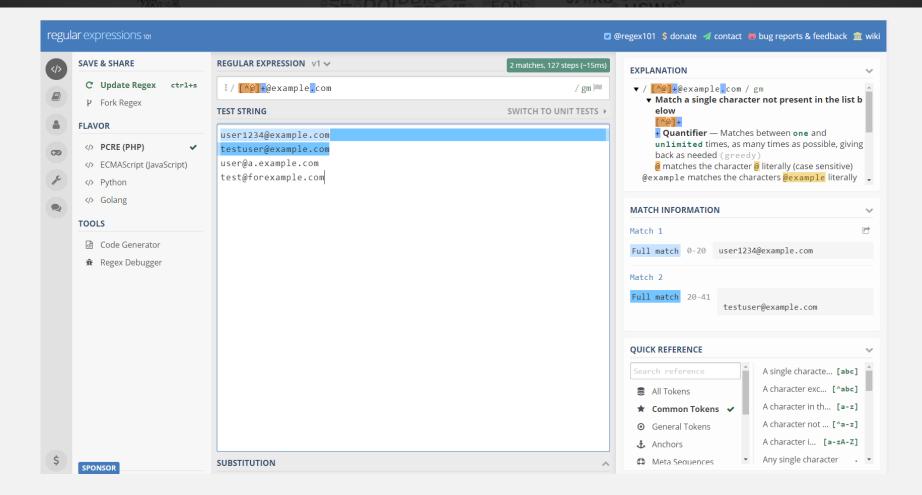
Виды синтаксиса:

- BRE = POSIX Basic Regular Expressions
- ERE = POSIX Extended Regular Expressions
- PCRE = Perl-Compatible Regular Expressions
- C++, .NET, JavaScript, Ruby, Java, везде разный синтаксис

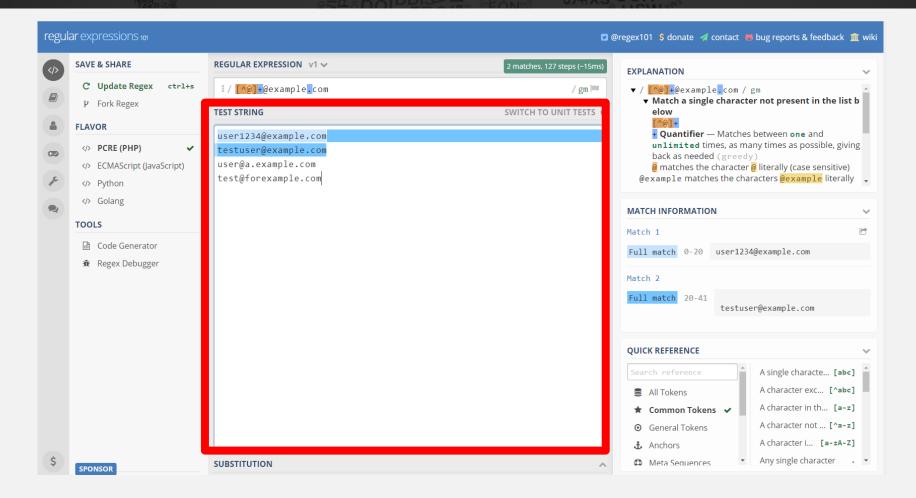
Виды реализаций:

- DFA через детерминированные автоматы
- NFA через недетерминированные автоматы

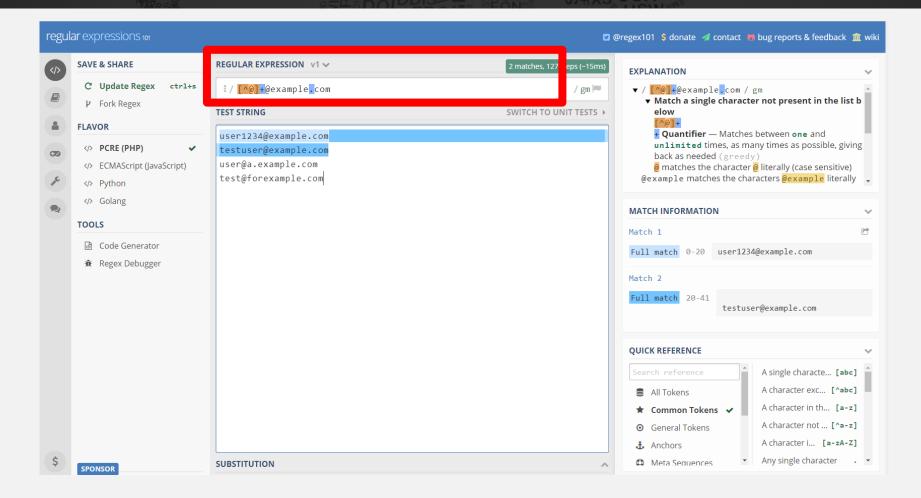




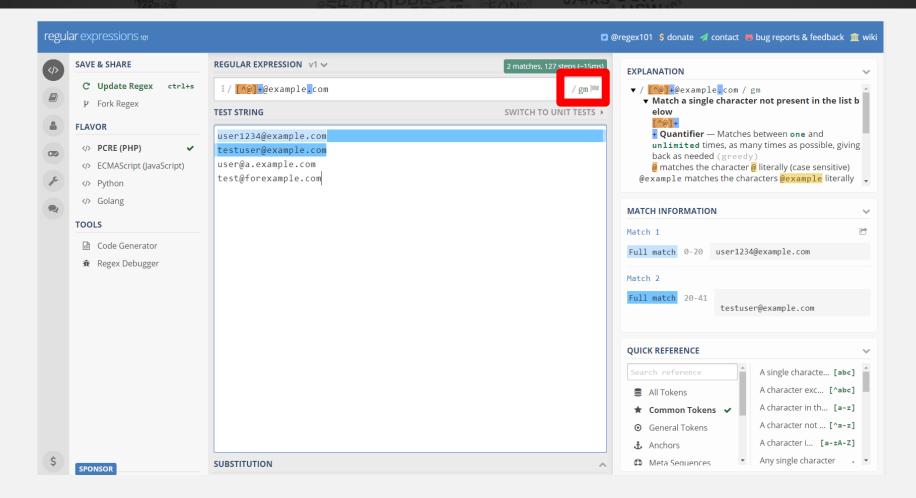




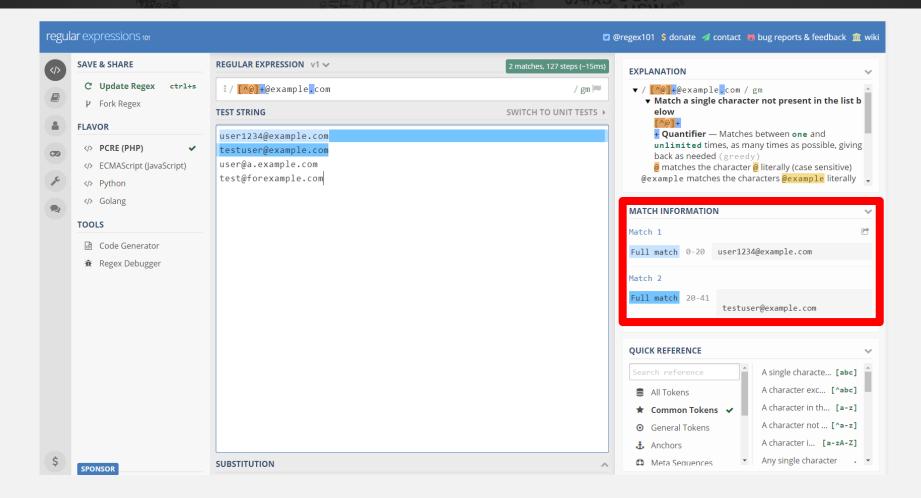




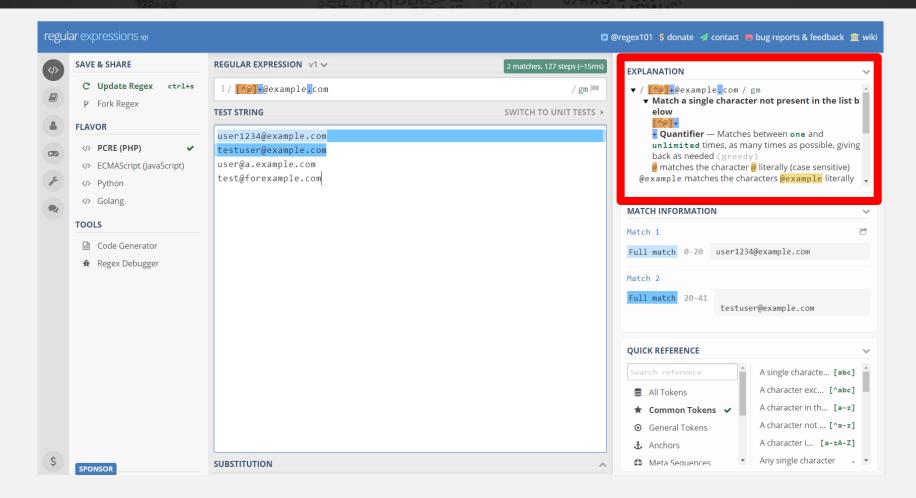




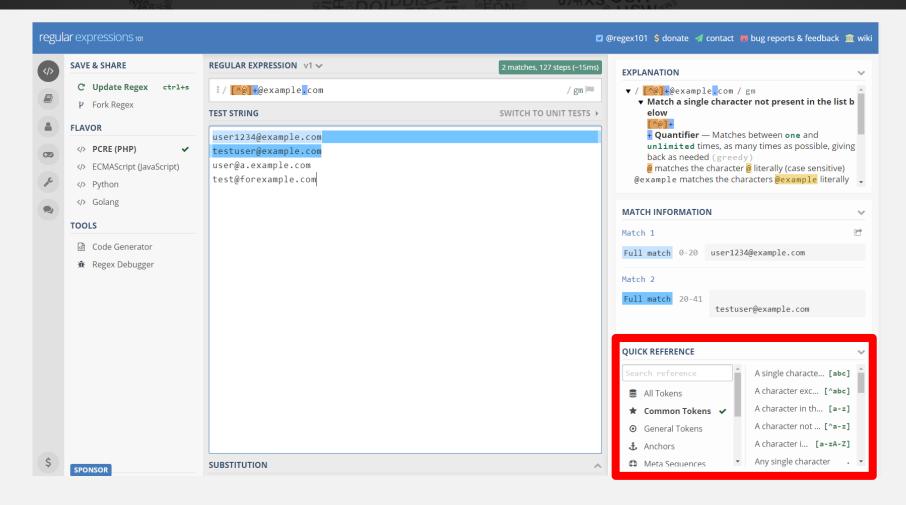




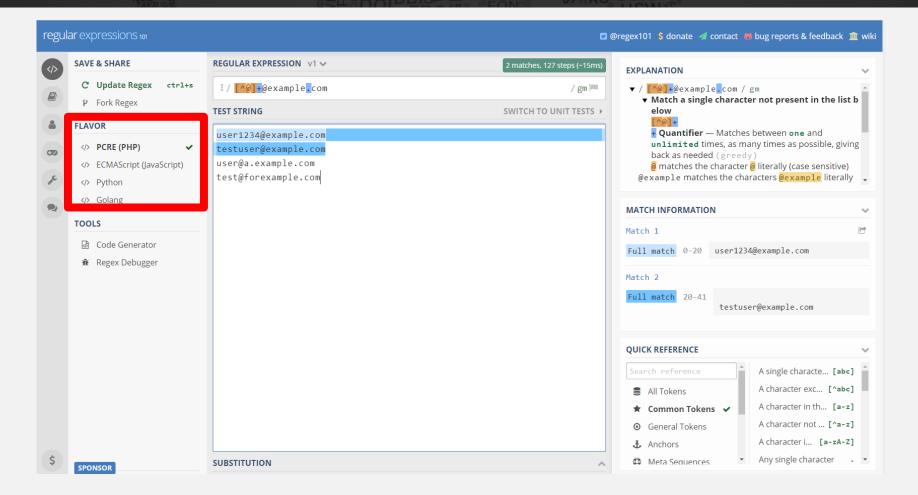














Основы регулярных выражений

Алфавит — Unicode

Служебные символы
$$-[]{}()|\.+*?^$$$

Экранирование	\ <sym></sym>
Конкатенация	<first><second></second></first>
Чередование	<first> <second></second></first>
Группировка	(<first>)</first>
Любой символ	•















Invalid	Valid
<pre>#include<stdlib.h></stdlib.h></pre>	<pre>#include <stdlib.h></stdlib.h></pre>
<pre>#include "stdio.h"</pre>	<pre>#include "stdlib.h"</pre>
<pre>#include 'helper.hpp'</pre>	<pre>#include <helper.hpp></helper.hpp></pre>
<pre>#include "HELPER.HPP"</pre>	<pre>#include "helper.hpp"</pre>



Символьные классы

- [abcde] любой из перечисленных символов
- [^abcde] любой символ кроме перечисленных
- [a-t] задание диапазона символов

Класс	Эквивалент	Описание	Отрицание
\d	[0-9]	Цифры	\D
\ s	[\f\n\r\t\v]	Пробелы	\ S
\w	[a-zA-Z0-9_]	Буква, цифра, подчеркивание	\W



#include (<|")\w\w\w\w\w\\(h|hpp)("|>)



#include $(<|")\w\w\w\w\.(h|hpp)("|>)$



Invalid	Valid
<pre>#include <std.io.h></std.io.h></pre>	<pre>#include <stdlib.h></stdlib.h></pre>
<pre>#include "std-io.h"</pre>	<pre>#include "stdlib.h"</pre>
<pre>#include <ab csv.hpp=""></ab></pre>	<pre>#include <helper.hpp></helper.hpp></pre>
<pre>#include "/csv.hpp"</pre>	<pre>#include "helper.hpp"</pre>



Квантификаторы

Синтаксис: <expr><quant>

Ищется максимальное вхождение

{n}	Ровно n раз
{m,n}	От m до n раз
{m,}	Не менее m раз
{,n}	Не более п раз
$\{0,1\} = ?$	0 или 1 раз
{0,} = *	0 и более раз (любое количество раз)
{1,} = +	1 и более раз





```
#include[ \t]*
(<|")[\.\\\/:\w]+\.(h|hpp)("|>)
```



```
#include[ \t]*
(<|")[\.\\\/:\w]+\.(h|hpp)("|>)
```



```
#include[ \t]*
(<|")[\.\\\/:\w]+\.(h|hpp)("|>)
```

```
Valid
```

```
#include "C:\\Users\\Admin\\Desktop\\project\\helper.hpp"
#include "../helper.hpp"
#include "project/helper.hpp"
#include<stdio.h>
```



Символы позиционирования

Позиционируют регулярное выражение в строке относительно начала/конца строки/слова.

٨	Начало текста	^cat	<pre>catdog catdog</pre>
\$	Конец текста	dog\$	catdog catdog
\b	Граница слова	\bcat	catcat catcat
\B	Не граница слова	\Bcat	catcat catcat



(?<mod>), (?-<mod>) – в начале выражения включает/выключает модификатор



g(global)

Искать все вхождения

\d

g	-g
1 2 3 4 5	1 2 3 4 5



m(multi-line)

^\$ соответствуют началу/концу строк

^is\$

m	-m
is	is
is this his	this
his	his



i(insensitive)

Отключить чувствительность к регистру

i	-i
a b C D E	a b C D E



x(extended)

Можно писать комментарии после #. Пробелы игнорируются.

```
\d #Цифры
```

\s #Пробелы

\w #Буква, цифра, подчеркивание

X	-X
1 b 2 c 3 d	1 b 2 c 3 d



s(single-line)

Точка (.) соответствует символу новой строки

*

S	-S
123	123
123 456	456



Проблема

```
Firstname
Lastname
Age

Jill
Smith
50

Eve
Jackson
40

Ctr>
Eve
Jackson
```



Проблема



Ленивые квантификаторы

Ищут минимальное вхождение.

Синтаксис:

<expr><quant>?

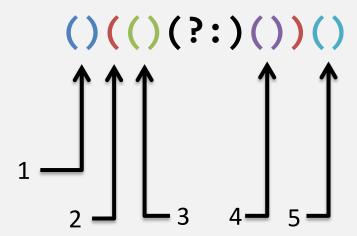


Решение



Группировка и захваты

```
    (<expr>) — захватывающая группа
    (?:<expr>) — незахватывающая группа
    (?<name><expr>) — именованная группа
    Нумерация групп (кроме именованных)
```





```
^(?:8|\+7[\-]?)?
(\(?\d{3}\)?[\-]?)?
([\d\-]{7,10})$
```



```
^(?:8|\+7[\-]?)?
(\(?\d{3}\)?[\-]?)?
([\d\-]{7,10})$
```



```
^(?:8|\+7[\-]?)?
(\(?\d{3}\)?[\-]?)?
([\d\-]{7,10})$
```



```
^(?:8|\+7[\-]?)?
(\(?\d{3}\)?[\-]?)?
([\d\-]{7,10})$
```



```
^(?:8|\+7[\-]?)?
(\(?\d{3}\)?[\-]?)?
([\d\-]{7,10})$
```

Full match	+79261234567
Group 1	926
Group 2	1234567



```
^(?:8|\+7[\-]?)?
(\(?\d{3}\)?[\-]?)?
([\d\-]{7,10})$
```

Full match	7331111
Group 1	undefined
Group 2	7331111



Ссылки назад

В регулярном выражении можно ссылаться на уже совпавшие группы.

Синтаксис:

```
\n\in[0;99] \1, \2, ... \g{<n>} \g{<n>} \g{\sigma}, \g{2}, ... \g{<\angle} \g{<\angle}, \g{\sigma}, \g{\sigma}, \g{\sigma}, ...
```











Invalid	Valid
"abc'	"abc"
	11 11
	'abc'



Условный оператор

Проверяет было ли найдено соответствие для предыдущей группы по имени или номеру (либо для выражения нулевой длины).

Синтаксис:



```
(?(<name>)<first>|<second>)
```



```
(?(<name>)<first> <second>)
```

```
(?<comment>^\/\/)?
.*
(?(<comment>)(\n)|(;\n)$)
```



```
(?(<name>)<first>|<second>)
```

```
(?<comment>^\/\)?
.*
(?(<comment>)(\n)|(;\n)$)
```



```
(?(<name>)<first>|<second>)
```

```
(?<comment>^\/\/)?
.*
(?(<comment>)(\n)|(;\n)$)
```



```
(?(<name>)<first>|<second>)
```

```
(?<comment>^\/\/)?
.*
(?(<comment>)(\n)|(;\n)$)
```



```
(?(<name>)<first>|<second>)
```

```
(?<comment>^\/\/)?
.*
(?(<comment>)(\n)|(;\n)$)
```



Invalid	Valid
int x = 0	int x = 0;
	// int x = 0
	// int x = 0;



$$(?(?=^\/\/)(.*\n)|(.*;\n)$)$$



$$(?(?=^)/)(.*)n)|(.*;\n)$)$$



$$(?(?=^{//})(.*,n)|(.*;n)$)$$



$$(?(?=^{//})(.*\n)|(.*;\n)$)$$



Invalid	Valid
int x = 0	int x = 0;
	// int x = 0
	// int x = 0;



Заглядывание вперед (выражение нулевой длины)

Просматривание последующего текста без включения в найденное.

Синтаксис:

```
(?=<expr>) — позитивное
(?!<expr>) — негативное
```







```
(?!<expr>)
```

$$d+(?!,)$$



```
(?!<expr>)
```

$$d+(?!,)$$



Оглядывание назад (выражение нулевой длины)

Просматривание предыдущего текста без включения в найденное.

Квантификаторы запрещены.

Синтаксис:

```
(?<=<expr>) — позитивное
(?<!<expr>) — негативное
```



$$(?<=, \slashs)(\d+)$$









Замена текста

Большинство программ позволяют производить замену по регулярным выражениям.

В замещающем тексте можно использовать захваченные группы.



Поиск	(\d+)u
Замена	\1 или \$1

Исходный текст:	Результат:
const auto $x = 1u$;	const auto x = 1;



```
#include <iostream>
#include <string>
#include <regex>
int main()
    std::string fnames[] = {"foo.txt", "bar.txt", "zoidberg"};
    std::regex txt regex("[a-z]+\\.txt");
    for (const auto &fname : fnames) {
        std::cout << fname << ": " << std::regex match(fname, txt regex) << '\n';</pre>
```



```
#include <iostream>
#include <string>
#include <regex>
int main()
    std::string fnames[] = {"foo.txt", "bar.txt", "zoidberg"};
    std::regex txt regex("[a-z]+\\.txt");
    for (const auto &fname : fnames) {
        std::cout << fname << ": " << std::regex match(fname, txt regex) << '\n';</pre>
```



```
#include <iostream>
#include <string>
#include <regex>
int main()
    std::string fnames[] = {"foo.txt", "bar.txt", "zoidberg"};
    std::regex txt_regex("[a-z]+\\.txt");
    for (const auto &fname : fnames) {
        std::cout << fname << ": " << std::regex match(fname, txt regex) << '\n';</pre>
```



```
#include <iostream>
#include <string>
#include <regex>
int main()
    std::string fnames[] = {"foo.txt", "bar.txt", "zoidberg"};
    std::regex txt regex("[a-z]+\\.txt");
    for (const auto &fname : fnames) {
        std::cout << fname << ": " << std::regex_match(fname, txt_regex) << '\n';</pre>
```



```
#include <iostream>
#include <string>
#include <regex>
int main()
    std::string fnames[] = {"foo.txt", "bar.txt", "zoidberg"};
    std::regex txt regex("[a-z]+\\.txt");
    for (const auto &fname : fnames) {
        std::cout << fname << ": " << std::regex match(fname, txt regex) << '\n';</pre>
foo.txt: 1
bar.txt: 1
zoidberg: 0
```



return 0;

```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
```



return 0;

```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
```



return 0;

```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
```



```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
   return 0;
```



return 0;

```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex_search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
```



return 0;

```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
```



return 0;

```
#include <iostream>
#include <string>
#include <regex>
int main()
   std::string s("this subject has a submarine as a subsequence");
   std::smatch m;
   std::regex e("\\b(sub)([^ ]*)");
   std::cout << "Target sequence: " << s << std::endl;</pre>
   std::cout << "Regular expression: /\b(sub)([^ ]*)/" << std::endl;</pre>
   std::cout << "The following matches and submatches were found:" << std::endl;</pre>
   while (std::regex search (s,m,e))
      for (auto x:m) std::cout << x << " ";
      std::cout << std::endl;</pre>
      s = m.suffix().str();
```



std::regex_search

Target sequence: this subject has a submarine as a subsequence

Regular expression: /\b(sub)([^]*)/

The following matches and submatches were found:

subject sub ject submarine sub marine subsequence sub sequence



```
#include <iostream>
#include <regex>
#include <string>
int main()
   std::string text = "Quick brown fox";
   std::regex vowel re("a|o|e|u|i");
   std::cout << std::regex replace(text, vowel re, "[$&]") << '\n';</pre>
```



```
#include <iostream>
#include <regex>
#include <string>
int main()
   std::string text = "Quick brown fox";
   std::regex vowel re("a|o|e|u|i");
   std::cout << std::regex_replace(text, vowel_re, "[$&]") << '\n';</pre>
```



```
#include <iostream>
#include <regex>
#include <string>
int main()
   std::string text = "Quick brown fox";
   std::regex vowel_re("a|o|e|u|i");
   std::cout << std::regex_replace(text, vowel_re, "[$&]") << '\n';</pre>
```



```
#include <iostream>
#include <regex>
#include <string>
int main()
   std::string text = "Quick brown fox";
   std::regex vowel re("a|o|e|u|i");
   std::cout << std::regex_replace(text, vowel_re, "[$&]") << '\n';</pre>
```



```
#include <iostream>
#include <regex>
#include <string>
int main()
   std::string text = "Quick brown fox";
   std::regex vowel re("a|o|e|u|i");
   std::cout << std::regex_replace(text, vowel_re, "[$&]") << '\n';</pre>
Q[u][i]ck br[o]wn f[o]x
```



Ссылки

regex101.com

rexegg.com

regular-expressions.info

habr.com/ru/post/166777/





Q&A

